

Projekt dotyczy analizy danych i implementacji modeli uczenia maszynowego do przewidywania wybranych wartości.

1. Wybór zbioru danych (kaggle, Wikipedia ...)
2. Zadanie typu klasyfikacja lub regresja
3. Lepiej wybrać dane o średniej wielkości (do ok. 20 kolumn i do kilkuset tyś. wierszy)
4. Projekty mają być umieszczone na githubie w indywidualnych repozytoriach.
5. Każde repozytorium z projektem powinno zawierać plik readme. z opisem danych, celem analizy i z wynikami.
6. Projekty należy zamieścić w notatniku Google Colab lub Jupyter Notebook
7. Jeśli ktoś nie umieści komendy pobierającej dane wewnątrz notatnika, to należy wykorzystywany plik z danymi umieścić w repozytorium.
8. Analizy powinny uwzględniać: wizualizację danych, analizę korelacji, czyszczenie i uzupełnianie danych (jeśli to konieczne), implementację kilku (co najmniej 2 modeli), porównanie ich wyników i wskazanie lepszego.
9. Sugerowane modele do regresji: Linear Regression, Polynomial Regression, Decision Tree, Random Forest.
10. Sugerowane modele do klasyfikacji: Logistic Regression, Decision Tree, Random Forest
11. Polecam użyć funkcji do automatycznego dobierania hiper parametrów - grid search, random search,
12. Wynik regresji oceniamy za pomocą RMSE (root mean squared error), a klasyfikacji za pomocą classification_report (zwracamy uwagę na F1-score).
13. Należy się wzorować notatnikiem P2Lab10_housing-essential-ml, który jest w folderze Lab, w repozytorium Programowanie 2
14. Dobrą pomocą jest również książka, którą polecałem na zajęciach - "Hands-on Machine Learnig with Scikit-Learn, Keras & TensorFlow" - wydanie 2 lub 3, szczególnie rozdział 1, 2 i 3.
15. Będziemy zwracać uwagę przede wszystkim na działanie kodu i zrozumienie go. Tego będą dotyczyć głównie pytania w trakcie prezentacji i na kolokwium.
16. Prezentacje są 11.06 i 15.06 - dla tych którzy nie zdążą lub nie będą mogli prezentować w pierwszym terminie (przed kolokwium pisemnym).
17. Wszystkie notatniki muszą być umieszczone na githubie i linki do waszych githubów muszą zostać wysłane do prowadzących grupy najpóźniej do 23.59 10.06!
18. Projekty wysłane wcześniej mają szansę na wstępną ocenę i sugestie poprawek. (prawdopodobieństwo sprawdzenia maleje wraz ze zbliżającym się terminem prezentacji)